

Machine learning – Agrégation de modèles

TP noté Master SDDP

2026-2027

On considère le jeu de données **ESCAP.csv** tiré des résultats de l'enquête ESCAPAD 2017. Cette enquête est présentée aux appelés (environ 40 000 appelés) à la Journée Défense Citoyenneté (JDC). Seule une partie des réponses vous est fournie : elle concerne le tronc commun (qui porte sur la situation personnelle des appelés) et le module B (qui porte sur la consommation de boissons alcoolisées).

La variable à prédire est la variable quantitative Q19A, « Age au premier alcool ».

Les variables pouvant être utilisées comme prédicteurs sont les suivantes :

Variable	Label	Modalités Valeur : Label
A01	Identifiant individu	
Q03	Sexe	1 : Homme 2 : Femme
Q04	Situation	1 : Vous suivez des études 2 : Vous avez arrêté vos études
Q04A	Situation scolaire	1 : Lycée(ne) ou collégien(ne) 2 : En apprentissage 3 : Etudiant(e) de l'enseignement supérieur (Université, IUT, BTS, prépa...)
Q04B	Situation professionnelle	1 : Sans activité 2 : En recherche d'emploi 3 : En insertion (contrat aidé, école de la 2ème chance, centre EPIDE...) 4 : Vous travaillez (hors apprentissage)
Q05	Redoublement	1 : Non 2 : Oui
Q06A	Difficultés pour lire	1 : Non 2 : Oui, parfois 3 : Oui, souvent
Q06B	Difficultés pour écrire	1 : Non 2 : Oui, parfois 3 : Oui, souvent

Q08	Lieu de vie	1 : Chez vos parents ou l'un de vos parents 2 : En internat 3 : Dans un foyer ou une famille d'accueil 4 : Dans votre propre logement (avec des amis, seul(e) ou avec votre conjoint) 5 : Autres situations (sans logement, caravane...)
-----	-------------	--

Variable	Label	Modalités
Q08C	Vie des parents	1 : Ils vivent ensemble 2 : Ils sont séparés ou divorcés 3 : Vous ne les avez jamais connus 4 : Ils sont décédés ou l'un d'entre eux est décédé 5 : Autres situations
Q09A1	Situation du père	1 : Travaille 2 : Chômeur, recherche un emploi 3 : Au foyer ou sans activité professionnelle 4 : En invalidité ou en longue maladie 5 : Retraité 6 : Je ne sais pas 7 : Non-concerné(e) (décédé(e), inconnu(e), perdu(e) de vue...)
Q09B1	Situation de la mère	1 : Travaille 2 : Chômeur, recherche un emploi 3 : Au foyer ou sans activité professionnelle 4 : En invalidité ou en longue maladie 5 : Retraité 6 : Je ne sais pas 7 : Non-concerné(e) (décédé(e), inconnu(e), perdu(e) de vue...)
Q10A1	PCS du père	1 : Agriculteur exploitant 2 : Artisan, commerçant, chef d'entreprise de moins de 10 salariés 3 : Chef d'entreprise de 10 salariés ou plus 4 : Cadre, professeur, chercheur, ingénieur, profession libérale 5 : Profession intermédiaire, technicien 6 : Employé 7 : Ouvrier 8 : Sans profession 9 : Non concerné(e) (décédé(e), inconnu(e), perdu(e) de vue. . .)

Q10B1	PCS de la mère	1 : Agriculteur exploitant 2 : Artisan, commerçant, chef d'entreprise de moins de 10 salariés 3 : Chef d'entreprise de 10 salariés ou plus 4 : Cadre, professeur, chercheur, ingénieur, profession libérale 5 : Profession intermédiaire, technicien 6 : Employé 7 : Ouvrier 8 : Sans profession 9 : Non concerné(e) (décédé(e), inconnu(e), perdu(e) de vue. . .)
B08A	Le père boit de l'alcool à la maison	1 : Non, jamais 2 : Peu de fois dans l'année 3 : 1 ou 2 fois par mois 4 : Au moins 1 fois par semaine 5 : Presque chaque jour

Variable	Label	Modalités
B08B	La mère boit de l'alcool à la maison	1 : Non, jamais 2 : Peu de fois dans l'année 3 : 1 ou 2 fois par mois 4 : Au moins 1 fois par semaine 5 : Presque chaque jour

Mettre en œuvre différents modèles de prédiction de l'âge au premier alcool (bagging, RF, boosting, stacking). Comparer leur performance.

Ne pas oublier, en préalable, de faire un peu de statistique descriptive...et peut-être d'en tirer certaines conclusions. A noter, il existe une variable de pondération (poids de sondage) dans la base : pm17B